

BLOC D • SÉANCES 7 À 11

Intégration dans une application web

Le coeur du module : votre métier



Les séances de ce bloc

1

Séance 7

Une API LLM est une API HTTP comme les autres

2

Séance 8

Architecture et sécurité d'une intégration

3

Séance 9

Une fonctionnalité IA de bout en bout

4

Séance 10

Function calling : le modèle appelle votre code

5

Séance 11

Choisir son modèle sur pièces

SÉANCE 7 • INTÉGRATION

Une API LLM est une API HTTP comme les autres

45 minutes de cours, puis le premier contrôle continu

Au programme aujourd'hui

1

Lire

L'anatomie d'une requête et d'une réponse

2

Échouer

Les erreurs propres aux modèles, et quoi en faire

3

Streamer

Recevoir la réponse au fil de l'eau

4

Composer

Contrôle continu n° 1, 45 minutes

Rien que vous ne sachiez déjà faire

1

Une URL

``/v1/chat/completions``, en local comme chez un fournisseur.

2

Un en-tête

``Content-Type``, et ``Authorization`` dans le cloud.

3

Un corps JSON

le modèle, les messages, les réglages.

4

Une réponse JSON

les choix produits, et le compte de tokens.

La même requête, en local et dans le cloud

en local : pas d'authentification, tout reste chez vous

```
curl http://localhost:11434/v1/chat/completions \  
  -H 'Content-Type: application/json' \  
  -d '{"model": "qwen2.5:3b", "messages": [...]}'
```

dans le cloud : deux choses changent, pas une de plus

```
curl https://api.exemple.com/v1/chat/completions \  
  -H 'Content-Type: application/json' \  
  -H 'Authorization: Bearer $CLE_API' \  
  -d '{"model": "un-modele-du-fournisseur", "messages": [...]}'
```

L'URL de base et l'en-tête d'authentification. C'est tout. Votre code de séance 9 fonctionnera des deux côtés.

Un appel robuste, dans les deux langues

PYTHON

```
try:
    r = httpx.post(
        URL, json=corps,
        timeout=30.0)
    r.raise_for_status()
except httpx.TimeoutException:
    return replier()
except httpx.HTTPStatusError as e:
    log(e.response.status_code)
    return replier()
```

JAVASCRIPT

```
try {
    const r = await fetch(URL, {
        method: "POST", body: corps,
        signal: AbortSignal
            .timeout(30000),
    });
    if (!r.ok) throw new Error(r.status);
} catch (e) {
    log(e.message);
    return replier();
}
```

Un timeout explicite n'est pas une option : un modèle surchargé peut ne jamais répondre.

Ce qui va casser, et ce qu'il faut en faire

Symptôme	Cause	Réaction
401	clé absente ou périmée	échouer vite, alerter
429	quota ou débit dépassé	réessayer, délai croissant
5xx	panne côté fournisseur	réessayer trois fois
Pas de réponse	modèle saturé	timeout, puis repli
JSON invalide	le modèle a divagué	valider, redemander une fois

Les deux dernières lignes n'existent pas dans vos API habituelles. Ce sont celles qui vous surprendront.

Recevoir la réponse au fil de l'eau

```
# le serveur pousse des evenements SSE, un par fragment
corps = {"model": MODELE, "messages": msgs, "stream": True}

with httpx.stream("POST", URL, json=corps) as flux:
    for ligne in flux.iter_lines():
        if not ligne.startswith("data: "):
            continue
        if ligne == "data: [DONE]":
            break
        bloc = json.loads(ligne[6:])
        print(bloc["choices"][0]["delta"].get("content", ""),
              end="", flush=True)
```

Côté navigateur, la même chose se lit avec EventSource ou en parcourant le flux de la réponse.

Un SDK, pour quoi faire au juste

Vous savez maintenant tout faire à la main. Un SDK vous fait gagner ceci.

- **Il gère les réessais** : et les délais croissants, correctement
- **Il découpe le flux** : vous itérez sur des fragments, pas sur des lignes
- **Il type les réponses** : l'autocomplétion de votre éditeur fonctionne
- **Ce qu'il vous cache** : le coût réel, les en-têtes de quota, et la simplicité du contrat sous-jacent

Contrôle continu n° 1, maintenant

- 45 minutes, individuel, sur feuille, sans machine.
- Première partie : vocabulaire et concepts des séances 1 à 6.
- Seconde partie : un calcul de coût et de latence, cloud contre local.



Ce qui est attendu

Des ordres de grandeur justes et un raisonnement lisible. Les chiffres exacts ne sont pas demandés de mémoire.

Une API comme les autres

- ✓ Même contrat en local et dans le cloud : seules l'URL et l'authentification changent.
- ✓ Timeout explicite, réessais avec délai croissant, et un plan de repli.
- ✓ Deux erreurs nouvelles : le modèle qui ne répond plus, et le JSON invalide.
- ✓ Le streaming se lit ligne par ligne, en SSE, et transforme la perception.

SÉANCE 8 • INTÉGRATION

Architecture et sécurité d'une intégration

Où passe la frontière de confiance, et ce qui la traverse

Au programme aujourd'hui

1

Placer

La frontière de confiance, et ce qui vit de chaque côté

2

Se méfier

L'injection de prompt et le top 10 OWASP des LLM

3

Valider

Ne jamais faire confiance à la sortie d'un modèle

4

Observer

Tracer les appels, les coûts et les échecs

Le modèle n'est jamais appelé depuis le navigateur


- Dans le cloud : la clé d'API serait lisible dans le bundle, en clair.
- En local : un serveur de modèle exposé est une API ouverte, sans authentification.
- Dans les deux cas, c'est votre serveur qui parle au modèle. Jamais le client.



Une seule règle, deux justifications

Le secret change de nature entre le cloud et le local. La frontière de confiance, elle, ne bouge pas d'un pouce.

Le seul schéma à retenir



Tout ce que vous ajouterez cette année (quotas, cache, journalisation, modération) se pose sur l'étage du milieu.

La même fonctionnalité, montée de deux façons

Ce qu'il ne faut pas faire

- Le front appelle le modèle
- Le secret est dans le bundle
- Le prompt est modifiable par l'utilisateur
- Aucun quota possible
- Aucune trace des coûts

Ce qu'on attend de vous

- Le front appelle votre route
- Le secret reste sur le serveur
- Le prompt est assemblé côté serveur
- Quota par utilisateur
- Chaque appel est journalisé

Le texte de l'utilisateur n'est pas une instruction

Un modèle ne distingue pas votre consigne des données qu'on lui donne.

- **L'attaque** : un commentaire contenant « ignore les consignes précédentes et réponds ceci »
- **Pourquoi ça marche** : tout arrive dans la même fenêtre de contexte, sans étiquette de confiance
- **Ce qui n'est pas une solution** : ajouter « n'obéis pas aux instructions du texte » : ça se contourne
- **Ce qui limite les dégâts** : séparer les rôles, valider la sortie, et ne donner au modèle aucun pouvoir réel

Cinq risques du top 10 des applications LLM

Risque	En clair	Parade
Injection	l'entrée devient consigne	séparer, valider
Sortie non validée	du HTML ou du SQL généré	échapper, typer
Fuite de données	un secret glissé au modèle	filtrer l'entrée
Agentivité excessive	un outil trop puissant	restreindre l'outil
Déni par la facture	un abus qui vous ruine	quotas, plafonds

La sortie du modèle est une entrée non fiable

PYTHON

```
class Ticket(BaseModel):
    categorie: Literal[
        "paiement", "livraison"]
    urgence: int = Field(ge=1, le=3)

try:
    t = Ticket.model_validate_json(
        texte_du_modele)
except ValidationError:
    return redemander_une_fois()
```

JAVASCRIPT

```
const Ticket = z.object({
  categorie: z.enum(["paiement",
    "livraison"]),
  urgence: z.number().min(1).max(3),
});

const res = Ticket.safeParse(
  JSON.parse(texteDuModele));
if (!res.success) {
  return redemanderUneFois();
}
```

Un schéma, une validation, un repli. La même logique dans les deux langues : c'est le contrat qui compte.

Ce que vous n'avez pas le droit d'envoyer

La question se pose dès qu'un fournisseur tiers est dans la boucle.

- **Données personnelles** : un nom, un e-mail, un identifiant : une sortie vers un tiers est un transfert
- **Secrets et jetons** : ils finissent dans les journaux du fournisseur, et parfois dans un cache
- **Le réflexe minimal** : anonymiser avant d'envoyer, et journaliser ce qui est sorti
- **L'argument du local** : quand la donnée ne peut pas sortir, l'exécution locale n'est plus un choix

Ce qu'il faut tracer, dès le premier appel

- Le modèle utilisé, les tokens d'entrée et de sortie, la durée.
- L'issue : succès, timeout, JSON invalide, quota dépassé.
- Un identifiant de corrélation, pour relier une plainte à un appel.



Sans traces, pas de diagnostic

Un modèle qui se dégrade lentement ne lève aucune exception. Seules vos mesures le verront.

Trouver la faille dans trois architectures

- 1 Trois schémas d'application vous sont distribués.
- 2 Pour chacun : où passe la frontière de confiance ?
- 3 Quel est le secret, et de quel côté vit-il ?
- 4 Quelle entrée utilisateur atteint le modèle sans contrôle ?
- 5 Proposer la correction minimale, pas la refonte.

Objectif

Savoir lire une architecture d'intégration et en repérer les défauts avant d'écrire la moindre ligne.

Architecture et sécurité

- ✓ Le navigateur parle à votre serveur, votre serveur parle au modèle. Jamais autrement.
- ✓ L'entrée utilisateur n'est pas une consigne, et la sortie du modèle n'est pas fiable.
- ✓ On valide la sortie par un schéma, avec un repli en cas d'échec.
- ✓ Sans journalisation des tokens, de la durée et de l'issue, aucun diagnostic possible.

SÉANCE 9 • INTÉGRATION

Une fonctionnalité IA de bout en bout

Le front est fourni. Vous écrivez la route, dans votre langue.

Au programme aujourd'hui

1

Lire

Le contrat de route, identique pour toute la classe

2

Écrire

La route serveur, en Python ou en JavaScript

3

Streamer

Renvoyer la réponse au fil de l'eau

4

Vérifier

Faire passer la suite de conformité

Ce que fait votre route, dans l'ordre

1

Recevoir

Valider l'entrée du client avant toute chose.

2

Assembler

Construire le prompt côté serveur, jamais côté client.

3

Appeler

Interroger le modèle, avec timeout et repli.

4

Renvoyer

Streamer vers le front, et journaliser l'appel.

Le contrat de route, quelle que soit votre pile

Élément	Valeur imposée
Route	POST /api/resumer
Entrée	{ "texte": "...", "ton": "neutre direct" }
Sortie	flux SSE, un événement par fragment
Fin de flux	événement { "done": true, "usage": {...} }
Entrée invalide	code 400, corps { "erreur": "..." }
Modèle injoignable	code 503, corps { "erreur": "..." }

C'est ce tableau qui est testé, pas votre code. Le fichier app/CONTRAT.md fait foi.

La page est fournie, et vous n'y touchez pas

- Une page statique unique, identique pour tout le monde.
- Elle appelle `/api/resumer`` et affiche le flux au fil de l'eau.
- Toute modification du front est hors sujet et non notée.



Pourquoi c'est gelé

Parce que le sujet du cours est la route serveur. Un front commun rend les rendus comparables, quelle que soit la langue.

Un seul fichier ce jour-là : s09_resumer

```
# app/python/s09_resumer.py (ou app/node/s09_resumer.mjs)
@routeur.post("/api/resumer")
async def resumer(requete: Request):
    texte, ton = valider_resumer(...) # TODO 1
    messages = prompt_resumer(texte, ton) # TODO 2

    async def flux():
        # TODO 3 et 4 : appeler le modele, relayer les fragments
        # TODO 5 : cloturer par l'evenement done et l'usage

    return await flux_ou_503(flux())
```

Un fichier par séance. Tant qu'un TODO manque, la route répond 501 « à écrire » au lieu de planter.

Relayer un fragment, dans les deux squelettes

PYTHON

```
async def generer():
    async for frag in flux:
        bloc = json.dumps(
            {"delta": frag})
        yield f"data: {bloc}\n\n"

    fin = json.dumps(
        {"done": True,
         "usage": usage})
    yield f"data: {fin}\n\n"
```

JAVASCRIPT

```
for await (const frag of flux) {
    const bloc = JSON.stringify(
        { delta: frag });
    res.write(`data: ${bloc}\n\n`);
}

const fin = JSON.stringify(
    { done: true, usage });
res.write(`data: ${fin}\n\n`);
res.end();
```

Deux retours à la ligne après chaque événement : c'est le protocole SSE, et c'est l'oubli le plus fréquent.

Ce que la suite de tests va vérifier

Un seul verdict, valable pour toutes les langues de rendu.

- **Le cas nominal** : un texte valide produit un flux, puis un événement de fin avec l'usage
- **Le cas invalide** : un texte vide ou absent renvoie un 400, pas une exception
- **Le cas dégradé** : modèle éteint : 503 propre, sans attendre indéfiniment
- **La frontière** : aucune requête directe du navigateur vers le port du modèle

Construire la fonctionnalité

- 1 Choisir sa voie, puis lancer son serveur : make app ou make app-node.
- 2 Ouvrir s09_resumer : c'est le seul fichier de la séance.
- 3 Remplir les TODO 1 à 5, dans l'ordre.
- 4 Lancer make conforme SEANCE=9 jusqu'au vert.
- 5 Relever la latence du premier fragment et la durée totale.

Objectif

Repartir avec une fonctionnalité IA complète, conforme au contrat, dans la langue de votre choix.

Une fonctionnalité de bout en bout

- ✓ Le contrat de route est le livrable : la langue d'implémentation est libre.
- ✓ Le prompt est assemblé côté serveur, à partir d'une entrée validée.
- ✓ Le streaming SSE est un événement par fragment, terminé par l'usage.
- ✓ Un rendu est conforme quand la suite de tests passe, pas quand ça marche chez vous.

SÉANCE 10 • INTÉGRATION

Function calling : le modèle appelle votre code

Lui donner des mains, sans lui donner les clés

1

Au programme aujourd'hui

1

Déclarer

Décrire une fonction pour qu'un modèle sache la demander

2

Boucler

Le modèle demande, vous exécutez, il reprend

3

Verrouiller

Valider les arguments, restreindre les pouvoirs

4

Composer

Brancher un vrai outil sur la fonctionnalité de la séance 9

Le modèle n'exécute rien, il demande

- Vous lui décrivez des fonctions disponibles, avec leurs paramètres.
- Au lieu de répondre du texte, il peut répondre « appelle ceci, avec ces arguments ».
- C'est vous qui exécutez, et qui décidez si vous exécutez.



Le modèle propose, le serveur dispose

Rien ne s'exécute jamais tout seul. Ce malentendu est la source de la moitié des craintes sur les agents.

Quatre temps, toujours les mêmes

1

Déclarer

Envoyer la liste des outils avec la question.

2

Demander

Le modèle renvoie un appel d'outil et ses arguments.

3

Exécuter

Vous validez, puis vous exécutez votre code.

4

Reprendre

Vous renvoyez le résultat, le modèle rédige la réponse.

Décrire un outil : un schéma JSON, rien d'autre

```
OUTILS = [{  
  "type": "function",  
  "function": {  
    "name": "chercher_commande",  
    "description": "Retrouve une commande par son numero.",  
    "parameters": {  
      "type": "object",  
      "properties": {  
        "numero": {"type": "string",  
                    "description": "ex: CMD-2024-118"}},  
      "required": ["numero"],  
    }  
  }  
}]
```

La description est lue par le modèle : elle fait partie du prompt. Mesuré ici : description vague, 4 déclenchements sur 5 ; description précise, 5 sur 5.

La boucle complète, en Python

```
msgs = [{"role": "user", "content": question}]

d = appeler(msgs, outils=OUTILS)
appels = d["choices"][0]["message"].get("tool_calls")

for appel in appels or []:
    args = Args.model_validate_json(appel["function"]["arguments"])
    resultat = TABLE_DES_OUTILS[appel["function"]["name"]](args)
    msgs.append({"role": "tool", "tool_call_id": appel["id"],
                  "content": json.dumps(resultat)})

reponse = appeler(msgs)  # le modele redige a partir du resultat
```

Une table d'outils explicite : jamais de résolution dynamique du nom de fonction reçu du modèle.

Ce que le modèle ne doit jamais pouvoir demander

L'outil est une porte que vous ouvrez : sa taille est votre décision.

- **Pas de requête libre** : un outil « exécute ce SQL » est une injection avec une étape de plus
- **Pas d'écriture sans confirmation** : supprimer, payer, envoyer : un humain valide
- **Des arguments typés et bornés** : validés par un schéma avant exécution, comme toute entrée
- **Les droits de l'utilisateur** : l'outil s'exécute avec les permissions du demandeur, pas les vôtres

Ce que le socle sait vraiment faire

Ce qu'on lui donne	Déclenche	Arguments	Faux appels
Description vague	4 / 5	4 / 4	0 / 2
Description précise	5 / 5	5 / 5	0 / 2
+ consigne système	5 / 5	5 / 5	0 / 2

qwen2.5:3b, outil chercher_commande, 5 questions avec numéro et 2 sans. Quand il appelle, les arguments sont toujours bons.

C'est la description qui déclenche l'appel

- Les arguments produits sont corrects : ce n'est pas là que ça casse.
- Ce qui casse, c'est que le modèle réponde de lui-même sans appeler.
- Préciser à quel moment utiliser l'outil suffit à combler l'écart.



La consigne système n'a rien ajouté ici

Sur ce jeu, elle ne change aucun chiffre. Gardez-la comme ceinture de sécurité, pas comme rustine à une description bâclée.

Donner un outil à votre fonctionnalité

- 1 Ouvrir s10_assistant : les TODO 6 à 8.
- 2 TODO 6 : déclarer l'outil chercher_commande et son schéma.
- 3 TODO 7 : la table des outils, arguments validés avant exécution.
- 4 TODO 8 : boucler, exécuter, laisser le modèle rédiger.
- 5 make conforme SEANCE=10, puis provoquer un appel invalide.

Objectif

Comprendre que l'appel d'outil est une boucle que vous contrôlez entièrement, pas une délégation.

Function calling

- ✓ Le modèle demande un appel, il ne l'exécute jamais lui-même.
- ✓ La boucle : déclarer, demander, valider et exécuter, reprendre.
- ✓ Les arguments reçus sont une entrée non fiable : schéma obligatoire.
- ✓ Sur un petit modèle, le risque n'est pas l'argument faux, c'est l'appel oublié.

SÉANCE 11 • INTÉGRATION

Choisir son modèle sur pièces

Remplacer l'opinion par un tableau de mesures

Au programme aujourd'hui

1

Définir

Un jeu de cas issu de votre propre fonctionnalité

2

Mesurer

Quatre indicateurs, automatiquement

3

Comparer

Trois modèles sur le même banc

4

Trancher

Écrire la phrase qui justifie votre choix

Le seul classement qui vous engage est le vôtre

- Un benchmark public mesure une tâche moyenne sur des données publiques.
- Votre application a une tâche précise et des données à elle.
- Vingt cas réels tranchent mieux que n'importe quel classement.



Le banc d'essai est un livrable

Il resservira à chaque changement de modèle, et il est demandé au CC2.

Quatre étapes, dans cet ordre

1

Figer les cas

20 entrées réelles,
et la sortie attendue
pour chacune.

2

Figer le prompt

le même pour tous
les modèles, sans
exception.

3

Lancer le banc

chaque modèle,
chaque cas,
mesures
enregistrées.

4

Lire le tableau

et choisir le plus
petit qui passe.

Les quatre indicateurs à relever

Indicateur	Comment on le mesure	Seuil visé
JSON valide	part des sorties qui parsent	plus de 95 %
Exactitude	part des réponses attendues	à définir par vous
Premier fragment	temps jusqu'au premier token	moins de 2 s
Débit	tokens par seconde	plus de 15

Le script de mesure, fourni et à compléter


```
for modele in MODELES:
    for cas in CAS:
        t0 = time.perf_counter()
        sortie, usage = appeler(modele, PROMPT, cas.entree)
        duree = time.perf_counter() - t0

        resultats.append({
            "modele": modele,
            "json_ok": parse_ok(sortie),
            "exact": sortie == cas.attendu,
            "ttft": usage["ttft"], "duree": duree,
        })
```

Le prompt est une constante du script : le faire varier en même temps que le modèle rend la comparaison inexploitable.

À quoi ressemble un tableau rempli

Un exemple de banc d'essai rempli : le 3B suffit



Le 1B décroche sur le format : deux sorties sur cinq sont inexploitable.

Le 7B gagne huit points d'exactitude et triple le temps d'attente.

Ce qui fausse une mesure

Quatre erreurs qui rendent un tableau joli et faux.

- **Le premier appel** : il inclut le chargement du modèle en mémoire : à jeter
- **La température** : à zéro pour comparer, sinon vous mesurez du hasard
- **Trop peu de cas** : sur cinq cas, un écart de vingt points ne veut rien dire
- **La machine occupée** : un banc lancé pendant une compilation mesure votre ventilateur

Monter votre banc et choisir

- 1 Extraire 20 cas réels de votre fonctionnalité, avec le résultat attendu.
- 2 Lancer le banc sur llama3.2:1b, qwen2.5:3b et un troisième modèle.
- 3 Remplir la grille des quatre indicateurs.
- 4 Choisir le plus petit modèle qui passe vos seuils.
- 5 Écrire les trois lignes de justification, chiffres à l'appui.

Objectif

Produire la justification de choix de modèle exigée au CC2, et savoir la refaire dans six mois.

Choisir sur pièces

- ✓ Vingt cas issus de votre produit valent mieux que tous les classements publics.
- ✓ Un seul paramètre varie à la fois : le modèle, jamais le prompt.
- ✓ Quatre indicateurs : format valide, exactitude, premier fragment, débit.
- ✓ On retient le plus petit modèle qui passe les seuils, pas le meilleur.